変圧器オイル温度予測 PoC 技術検証報告

ETT（Electricity Transformer Temperature）データセットを用いた
時系列予測モデルの段階的検証

2026年2月

短期はPersistenceが最強。長期は強正則化Ridge(α=2000)がBL比-16%改善を達成。複雑なDLは不要、軽量モデルで十分

エグゼクティブサマリー

EDA

OT変動の91%は長期トレンド。PACF lag1=0.98で直前値への依存が極めて強い。
→ Persistenceが短期で極めて強力なベースラインになる構造

検証結果

BL→ML→DLの3段階検証。短期(1-6h)は全モデルがPersistenceに敗北。
長期(168h)ではRidge(α=2000)がBL比-16%改善（MAE 2.76→2.31）を達成

論文比較

Informer(seq=720)で論文値を超えるMAE=1.94(24h)を達成（論文2.27）。
しかしPersistence(1.63)にはなお及ばず。DLの費用対効果は低い

推奨

短期はPersistence、長期はRidgeの軽量モデルで運用を開始。
Phase 2では閾値定義と異常検知の評価を業務側と実施

ETTh1は2年間・1時間粒度のセンサデータ（7変数、17,420レコード）。欠損値なし

1. データ概要

項目	内容
データセット	ETTh1 (Electricity Transformer Temperature)
期間	2016/7/1 ~ 2018/6/26（約2年間）
粒度 / レコード数	1時間ごと / 17,420
目的変数	OT（Oil Temperature）
説明変数	HUFL, HULL, MUFL, MULL, LUFL, LULL（負荷変数6種）
欠損値	なし
分割	Train: 12ヶ月(8,640) / Val: 4ヶ月(2,880) / Test: 残り(5,900)

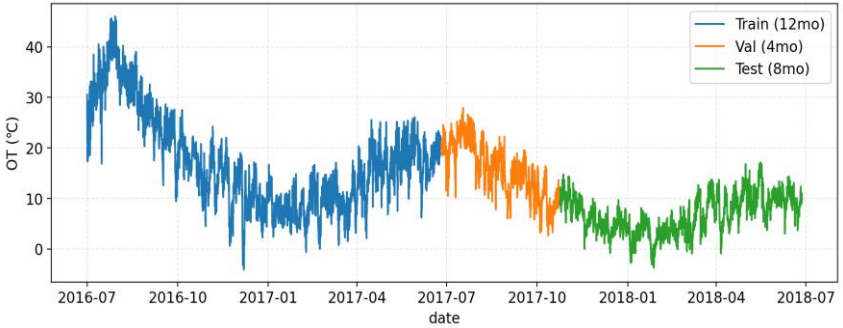

図1: データ全期間の推移と分割状況（学習・検証・テスト）

OT変動の91%は長期トレンド（熱慣性）。PACF lag1=0.98は「直前値がほぼ答え」を意味する

2. EDA — データ特性の把握

STL分解（period=168h）

成分	分散比	解釈
Trend	91.0%	長期の季節変動（外気温連動）
Seasonal	3.5%	日次パターン（日中高温/夜間低温）
Residual	6.9%	短期ノイズ・突発変動

トレンドが支配的
→ OTは短期的にはほとんど変化しない
→ ACFから日次周期(24h)は確認できるが、分散への寄与は小さい
→ Persistenceが強力なBLになることを示唆

自己相関分析

PACF lag1 = 0.98

直前値への依存が極めて強い。lag2以降はほぼゼロ

負荷変数との相関: 最大 r = 0.22（弱い）
→ モデルはOT自身の過去値に頼らざるを得ない

ADF検定: $p < 0.01$（定常）→ 差分不要

「MLは本当に必要か？」を問うため、ベースライン→ML→DLの3段階で段階的に検証

3. モデリング方針

Step 1: ベースライン

Persistence（直前値）
SeasonalNaive（24h周期）
Mean（学習平均値）

予測の「下限」を定義

Step 2: 機械学習

Ridge / LightGBM / XGBoost / RF
Direct + Recursive方式
EDA根拠の特徴量設計

特徴量で改善できるか

Step 3: DL

LSTM（系列圧縮）
PatchTST（Transformer自前実装）
Informer（公式実装）

系列全体の構造を捕捉

予測ホライズン: 1h（即時）/ 6h（当日）/ 24h（翌日）/ 168h（週次）— 保全アクションのリードタイムに対応

Persistenceが短期で最強。24h以上ではSeasonalNaiveと一致。これが全モデルの「壁」になる

4. Step 1 — ベースライン結果

モデル	1h MAE	6h MAE	24h MAE	168h MAE
Persistence	**0.44**	**1.16**	1.63	2.76
SeasonalNaive24	1.63	1.63	**1.63**	2.76
Mean	10.47	10.48	10.49	10.58

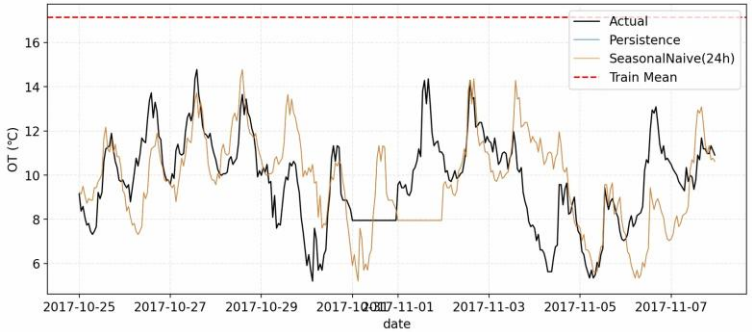

図2: ベースライン予測と実績値の比較（h=24h）

SeasonalNaive の定義（no leakage）：

$\hat{y}(t+h) = y(t + h - 24 \cdot \lceil h/24 \rceil)$

→ 予測対象と同じ時間帯の、直近の過去実測値を返す

→ h=168（=24×7）の場合、参照先はy(t)でPersistenceと一致

緑太字 = 各ホライズンの最良。MAEの単位は℃

初期設定ではBLに敗北。原因分析→正則化強化(α=2000)で168h MAE=2.31（BL比-16%改善）を達成

5. Step 2 — 機械学習モデル結果

モデル	α	1h MAE	24h MAE	168h MAE
Persistence	—	**0.44**	1.63	2.76
Ridge	1.0	0.67	1.93	2.75
LightGBM	—	0.79	3.14	6.33
Ridge（最適化）	**2000**	0.83	1.93	**2.31**

なぜα=2000で改善するか:

α小: OT_lag1（直前値）に過度に依存 → 168h先ではlag1が古く劣化
α大: lag1への依存を抑え、複数特徴量をバランスよく活用
→ 長期予測の過学習が減り汎化性能が向上

Val/Testの両方で改善を確認済み（Val: 2.82→2.49）
→ EDAの「ラグ劣化」分析を正則化で裏付けた形

LSTM/PatchTST/Informer全てがベースラインに敗北。Ridge(α=2000)が最もコスパが高い

6. Step 3 — DL/Transformerモデル結果

モデル	1h MAE	24h MAE	168h MAE	備考
Persistence	**0.44**	1.63	2.76	ベースライン
Ridge(α=2000)	0.83	1.93	**2.31**	ML最良（長期）
LSTM (lb=168)	0.47	2.72	5.89	短期のみ健闘
PatchTST	2.80	6.14	6.61	過学習（データ不足）
Informer (seq=168)	—	2.66	3.88	
Informer (seq=720)	—	1.94	3.66	論文値超だがBL未達

- 168h: Ridge(2.31) > Persistence(2.76) > Informer(3.66) — **軽量Ridgeが最良**
- 24h: Persistence(1.63) > Ridge(1.93) > Informer(1.94) — **短中期はBLが壁**
- 論文と同等水準のInformerを実装し、 同一条件でベースラインと比較した結果、 Persistenceが上回ることを確認した

→ DLの計算コスト（GPU×数時間）に対し、Ridge(α=2000)はCPU×数秒で同等以上

短期はBL最強、長期はRidgeが唯一BLを超えた。「複雑なDLは不要」がPoCの核心的知見

7. 検証結果の総括

モデル	評価
Persistence	短期(1-6h)で最強。全モデルの壁
SeasonalNaive	24h以上ではPersistenceと一致。独自の優位性は限定的
Ridge(α=2000)	168h MAE=2.31でBL比-16%。唯一BLを上回ったモデル
LightGBM	短期はRidgeに次ぐが長期で大幅悪化。ツリー系の外挿の弱さ
LSTM	1h MAE=0.47でPersistenceに迫るが、24h以降で急速に劣化
PatchTST	全ホライズン最下位。8,640サンプルでTransformerは過学習
Informer(720)	DL最良。論文値超だがBL/Ridgeには届かない

核心的知見: PACF lag1=0.98のデータでは「直前値を返す」Persistenceが短期で最強。長期ではlag1依存を正則化で抑えたRidgeが有効。DL(GPU×数時間)よりRidge(CPU×数秒)の方がROIが高い。

全4データセット・168h予測でRidgeが完全勝利。ETTh1で得た知見は他の変電所・粒度でも成立する

8. 汎化性検証 — 全4データセットでの比較

データセット	粒度	Persistence	SeasonalNaive	Ridge(α=2000)	Informer
ETTh1	1h	2.76	2.76	**2.31**	3.66
ETTh2	1h	5.70	5.70	**4.71**	4.85
ETTm1	15min	2.77	2.77	**2.31**	4.23
ETTm2	15min	5.70	5.70	**4.41**	5.21

Ridgeの改善率（vs Persistence）

データセット	Persistence	Ridge	改善
ETTh1	2.76	2.31	**-16%**
ETTh2	5.70	4.71	**-17%**
ETTm1	2.77	2.31	**-17%**
ETTm2	5.70	4.41	**-23%**

MAEの単位は全て℃。緑太字 = 各データセットの最良モデル

主要な知見:

1. Ridgeが全4データセットで最良（例外なし）

2. 改善率は-16%〜-23%で安定
   → ETTh1固有の結果ではなく汎用的

3. Informerは全データセットでRidgeに敗北
   → GPU×数時間の投資に見合わない

4. 1h粒度でも15min粒度でも同じ傾向
   → データ粒度に依存しない結論

EDA根拠に基づく設計判断、段階的検証、スケール統一、リーク検証を一貫して実施

9. 工夫した点・設計上の意思決定

工夫	詳細	根拠
特徴量設計	OTラグ (1,2,3,6,12,24,168h) 時間sin/cos, 月sin/cos HULL, MULL	ACF/PACFで有意なラグを特定 24h/168h周期をSTLで確認 相関分析でr>0.2の2変数を選定
段階的検証	BL→ML→DL の3段階 各段階でBLと比較	「ML/DLが本当に必要か」 を定量的に判断するため
正則化の最適化	Ridge α=1→2000で 168h MAE 16%改善	EDAの「ラグ劣化」分析を 正則化で裏付け
BLのリーク検証	SeasonalNaiveがh>24で 未来値を参照するバグを発見・修正	正しい比較のための前提条件

短期Persistence + 長期Ridgeの2モデル構成で運用開始。Phase 2で異常検知の業務要件を定義

10. Phase 2 への提案

推奨アクション

1. 軽量2モデル構成の運用組み込み（即時実行可能）
短期(1-6h): Persistenceで監視
長期(168h): Ridge(α=2000)で週次予測
予測バンド逸脱時にアラート発報

2. 外生データの取得検討
外気温・ファン稼働状態など「熱の先行指標」で予測精度向上の余地を探索

Phase 2で定義すべき業務要件

閾値の定義
何℃を超えたら「異常」とするか（業務側と合意）

誤警報/見逃しの許容基準
Precision/Recallの目標値（コスト非対称性を考慮）

運用アクションとリードタイム
アラート後に何をするか（点検/停止/冷却）

外生データの入手可否
外気温、ファン稼働、負荷スケジュール等

※閾値・誤警報コスト等が未定義のため、本PoCではPrecision/Recall評価は未実施。Phase 2の主要タスクとして位置づける

まとめ

1 短期はPersistence、長期はRidge

1-6h: Persistence(MAE=0.44℃)が全モデル中最強。追加投資の優先度は低い
168h: Ridge(α=2000)が全4データセットでBL比-16〜23%改善。完全勝利

2 DLは費用対効果が低い

Informerは全4データセットでRidgeに敗北。論文値超を達成しても実運用では不要
GPU×数時間 vs CPU×数秒。PoCフェーズではRidgeで十分

3 Phase 2は異常検知の業務定義から

予測精度の追求より、閾値定義・誤警報/見逃し基準を業務側と合意するのが先
軽量2モデル構成（Persistence+Ridge）で運用開始を推奨

参考
Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, H., & Zhang, W. (2021). *Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting.* **AAAI 2021**